

Számítási és tárolási felhők

(3. ea)

Üzleti PaaS szolgáltatások

Szeberényi Imre, Ludmány Balázs,
BME IIT

<szebi@iit.bme.hu>



MŰEGYETEM 1782

PaaS rendszerek célkitűzése

- Egyszerű környezetet adjanak (web) alkalmazások fejlesztésére és futtatására.
- A futtatást forgalom-függetlenül támogassák.
- A fejlesztőnek csak az alkalmazás elkészítésére kelljen koncentrálni.
- Automatikusan támogassák a skálázást.
- Serverless futtatás támogatása

Platform szolgáltatások



- Alkalmazás és szolgáltatás konténerek
- Konténer-orkesztráció (Kubernetes)
 - skálázás, önjavítás, frissítés menedzsment
- BP szolgáltatások
- Integrációs szolgáltatások
- Alkalmazásszervező szolgáltatások
- Alkalmazás életciklus menedzsment

Platform szolgáltatások /2

- Eseményfeldolgozás
- Funkciók futtatása idő- és eseményalapú triggerrel (FaaS)
- Átmeneti és perzisztens tárolás
- Registry és repository
- Azonosítás
- Biztonság

Programozási modell példák

- Actor model (message passing)
- RESTful interactions
- Dynamic recoverability
- Consensus protocols
- Asynchronous interactions
- Shared nothing and sharding
- Service orchestration
- MapReduce
- Event-driven komponensek

AppEngine



- Google PaaS szolgáltatása 2008-tól
- Serverless platform
- Támogatott nyelvek:
 - Java, Python, PHP, Go, Ruby, .NET, ...
- Adatbázis:
 - App Engine Datastore/Cloud Firestore (NoSQL)
 - Google Cloud SQL
 - Google Cloud Storage (REST)

AppEngine / 2

- Egyéb szolgáltatások:
 - URL fetch
 - Mail
 - Memcache
- Biztonság (Sandbox)
 - Internetről csak HTTP/HTTPS
 - Nincs lokális fájl írás
 - Válaszidő 60 sec
 - Válasz után nincs fork

AppEngine / 3

- Használatát mikor ajánlja a Google?
 - Nem kell servert telepíteni, karbantartani
 - Végtelen skálázhatóság
 - Előre nehezen becsülhető terhelés
 - A feladat darabolható (60s)
 - Nem kell lokális fájlrendszer

<https://console.developers.google.com/start/appengine>

<https://cloud.google.com/free-trial/>

AppScale

- AppScale szolgáltatása 2009-től
- Apache licence
- Támogatott nyelvek:
 - Java, Python, PHP, Go
- Támogatott platformok:
 - Google Compute Engine
 - Amazon (EC2)
 - Softlayer (IBM)
 - MS Azure
 - RackSpace
 - DigitalOcean
 - OpenStack
 - CloudStack
 - Eucalyptus
 - KVM
 - Xen

AppScale APIs



- Data management
 - MySQL, Cassandra, HBase, Hypertable, AWS SimpleDB, Azure SQL, Bigtable
 - Distributed transaction support, Memcache, blobstore
- Users
 - Messaging, email, authentication
- Tasking
 - Cron, task queues
- Web access
 - Fetch, export, user interaction

AppScale APIs /2

- Computation intensive
 - Parallel/concurrency support
 - MPI, X10
 - Distributed simulation (biochemistry)
- Data analytics
 - Map-reduce (hadoop, pig, hive)
 - R, Matlab
 - Yahoo! S4 (streaming)


<http://www.appscale.com/>

Amazon Beanstalk

- Amazon PaaS szolgáltatása 2011-től
- Támogatott nyelvek:
 - Python, Ruby, PHP, .NET, Java, Node.js
- Monitoring (CloudWatch)
- AutoScaling
- Load balancing
- Fejlesztő környezetek:
 - Management console, Git repo, IDE (Eclipse, Visual Studio)

<http://aws.amazon.com/elasticbeanstalk/>

Amazon Beanstalk szerver




- Terhelés-
kiegyenlített
szerverpark
- Amazon Route53
(DNS)
- Nem lehet kinőni.

Amazon SQS


SQS: Simple Queue Service

- Elosztott
- Redundáns
- At least-once-delivery
- Message sample
- Lifecycle
- Visibility timeout
- JMS kompatibilis



OpenShift


- Open source PaaS (RedHat → IBM)



OpenShift

- Red Hat PaaS szolgáltatása 2011-től
 - Red Hat felvásárlás: 2019. IBM
- Apache Licenc
- Alapvetően OpenStack felett fut, de más környezetekben is installálható
- Kubernetes-alapú környezet, vállalati policy-k
- Saját infrastruktúrán is telepíthető
- Támogatott nyelvek:
 - Haskell, Java, JavaScript, .NET, Perl, Python, Ruby
- Támogatott adatbázisok:
 - MS SQL, MongoDB, MySQL, PostgreSQL

OpenShift fejlesztési ciklus példa



Heroku

- Indulás: 2007, Salesforce, Ruby platform
- Ma: Támogatott nyelvek: Ruby, Java, Node.js, Python, PHP, Go, Scala, Clojure
- Dinók (dynos): konténer-alapú futtatási egységek
- Marketplace: több ezer add-on (DB, cache, monitoring, CI/CD)
- Adatbázis: Heroku Postgres, Redis
- Git-alapú deploy: `git push heroku main`
- Előny: nagyon gyors prototípus-fejlesztés, fejlesztőbarát
- Hátrány: költségesebb nagy terhelésnél, vendor lock-in

OpenShift vs. Heroku

- OpenShift:
 - vállalati, Kubernetes-alapú, rugalmas, de komplex
 - nagyobb cégeknek.
- Heroku:
 - fejlesztőbarát, SaaS jellegű, gyors indulás
 - startupoknak és prototípusokhoz.

Alibaba Cloud EDAS



- Enterprise Distributed Application Service (EDAS)
- Mikroszervizek, alkalmazásmenedzsment
- Fő funkciók: automatikus skálázás, terheléselosztás, szolgáltatás-regisztráció
- Integráció: Kubernetes, Spring Cloud, Dubbo
- Célcsoport: nagyvállalati alkalmazások, elosztott rendszerek
- Előny: szoros integráció az Alibaba Cloud ökoszisztémával
- Hátrány: erős vendor lock-in a kínai piacra

Számítási és tárolási felhők alapjai (4. ea)

Elosztott fájlrendszerek

Szeberényi Imre, Ludmány Balázs
BME IIT

<szebi@iit.bme.hu>



Tartalom



- Bevezetés
- AFS (történelem, architektúra)
- Lustre
- Ceph
- ZFS
- GlusterFS
- CERN rendszerek (CernVMFS, EOS)
- Összefoglalás / IO-500

Fájlrendszerek

CÉL: Adatok véletlen-szerű strukturált elérése

- bájt, rekord, adatbázis szinten
- hibatűrő módon
- Blokkos elérésű eszközökön megvalósított fájlrendszerek
 - Lokális
 - speciális hardver (szalag, CD/DVD, flash, SSD, ...)
 - Hálózaton keresztül
 - (meg)osztott
 - Elosztott
- Speciális adatok elérése (procfs, configfs, ...)

Osztott fájlrendszerek

- Blokkszintű hálózati eléréssel rendelkező eszközök (SAN) fölött működő kliensek biztosítják a hozzáférést és a kölcsönös kizárást.
 - CXFS (SGI)
 - Veritas Cluster FS
 - Nasan FS (DataPlow)
 - General Parallel FS (IBM)
 - Cluster Volumes (MS CSV)
 - Global FS (RedHat)
 - QFS (SUN)
 - VMFS (VMware)
 - Xsan (Apple)

http://en.wikipedia.org/wiki/List_of_file_systems

Elosztott fájlrendszerek

- Nagyméretű klaszterek
- Földrajzilag is elosztott rendszerek
- Heterogén környezet
- Hibatűrés, replikáció, migráció
 - FAL (DEC, 1970)
 - NFS (Sun, 1985)
 - AFS, CODA, InterMezzo
 - Lustre, SFS
 - GFS (Google)
 - GlusterFS (RedHat)
 - OCFS (Oracle, GNU)
 - Hadoop HDFS
 - BeeGFS (Fraunhofer)
 - Ceph (RedHat, SUSE)
 - Gfarm file System
 - GPFS (IBM)
 - OrangeFS (Parallel Virtual FS)
 - CernVMFS (Cern)
 - S3 (Amazon)
 - OneFS (EMC)
 - Moose FS (Core Tech)
 - DFS (MS)
 - ObjectiveFS (Objective Sec. Group)
 - CERN-EOS
 - Quobyte


AFS (Andrew File System)

- Elosztott fájlrendszer, ami fájlok megosztására alkalmas lokális és távolsági hálózaton.
- Transzparens fájlhozzáférést biztosít.
- Az NFS-hez hasonló, annak alternatívájaként jött létre.
- Ma az OpenAFS számos UNIX, LINUX, WinX platformon elérhető.
- CERN-ben ma is használják, bár 2020 óta kivezetés alatt van (helyette EOS), de sokszor jobban teljesít az öreg vasakon.

AFS történelem

- Carnegie Mellon Egyetemen 1984-ben fejlesztették ki UNIX környezetben. Ma azonban nem csak UNIX változat létezik.
- A fő cél az volt, hogy az egyetemi korlátozott sávszélességű hálózaton hatékony fájllelérést tegyenek lehetővé.

AFS processzek



AFS alapfogalmai

- Cellák
- Kötetek
- Tokenek
- Cache menedzser
- Fájl védelem
- Fájl névtér

AFS cella

- Egy AFS cella alá azok a szerverek tartoznak, melyek adminisztrációja közös, és az AFS felé egyetlen közös fájlrendszert alkotnak.
- Tipikusan az egy domain név alá tartozó gépek egy AFS cellát alkotnak.
- Általában a domain név valamilyen változata a cellanév.
- A munkaállomások a felhasználókról a cella szervertől kérnek információkat.

Kötetek

- A diszkterületet az AFS további részekre, osztja ezek az AFS kötetek.
- Az AFS kötet egy tárolóegység ami a fájlok és katalógusok adatait tárolja.
- Az AFS kötetek fájlok formájában jelennek meg a befogadó operációs rendszerben, így azok könnyen átmozgathatók, akár másik gépre is.

Tokenek

- **Az AFS** nem használja a UNIX felhasználói azonosítóját (UID). Ha ezt tenné, akkor minden UNIX gépen azonos UID kiosztásnak kellene lennie, mint az NFS-nél.
- Az azonosításhoz AFS tokenet alkalmaznak, ami egy egyedi azonosítást tesz lehetővé.
- Egy token adott ideig (24 óra) érvényes.


Cache menedzser

- A korlátozott sávszélesség miatt a működés központi eleme a cache, ahova az éppen használt fájlok letöltődnek.
- A cache menedzser feladata a cache-ben tárolt információk frissítése, karbantartása.
- Amennyiben a cache-ben tárolt fájlrészlet változik, úgy azt vissza kell tölteni a szerverre.
- Ha a szerveren változik meg a fájl, akkor arról Callback technikával értesít minden cache-t.

Védelem

- A védelmi mechanizmus némileg eltér az alap UNIX védelmi rendszertől.
- A UNIX 3x3-as védelmétől pontosabban szabályozható ACL (Access Control List) segítségével.
 - Lookup (l)
 - Insert (i)
 - Delete (d)
 - Administer (a)
 - Read (r)
 - Write (w)
 - Lock (k)

Névtér



Névtér /2

- UNIX-hoz hasonló hierarchikus struktúra
- Az AFS gyökér névtér rendszerint a /afs. Az alatta levő szinteket a cellák képviselik.
 - adminisztratív domain
 - AFS szerverek halmaza egy cégnél, egyetemen, laborban stb.
 - Lokális cella
 - alapértelmezett cella, amihez az adott munkaállomás csatlakozik.
 - idegen cella
 - más cella az AFS névtérben

Venus és Vice



- Venus
 - AFS kliens által futtatott processz.
- Vice
 - AFS szerver által futtatott processz.

Fájl műveletek

- A kliens munkaállomás a szerverrel csak az open/close műveletek kiszolgálásakor kommunikál.
- A fájl megnyitásakor a Venus a teljes fájlt a cache-be tölti, és a fájl lezárásakor írja azt vissza.
- Az adatok olvasását/írását a lokális másolaton a kernel végzi.
- A Venus a katalógusokat és a szimbólikus linkeket is a lokális gyorsítótárban tárolja.
- A fenti gyorsítótárazási mechanizmus alól a katalógusok módosítása a kivétel, aminek a végrehajtásáért a közvetlenül szerver a felelős.

Fájl megosztás

- Lokális fájlokhoz hasonlóan.
 - nincs külön mount
 - nem kell belépni a másik gépre
 - csak jogosultság kell
- A /afs katalógus alatt tetszőleges cella fájljai elérhetők.
 - Természetesen megfelelő jogosultsággal.
 - Csak a megfelelő útnevet kell hozzá tudni.
- A fájlmegosztást nem korlátozza a földrajzi távolság, vagy az adott operációsrendszer típusa.

Login és autentikáció

1. Bejelentkezéssel együtt token is generálódik
2. Külön kell token generálni.
 - klog,

```
Tokens held by the Cache Manager:
```

```
--End of list--
```

```
szebi:$ /usr/afs/bin/klog
```

```
Password:
```

```
szebi:$ /usr/afs/bin/tokens
```

```
Tokens held by the Cache Manager:
```

```
User's tokens for afs@bme.hu [Expires Apr  7 00:47]
```

```
--End of list--
```

```
.....
```


```
User's tokens for afs@cern.ch [Expires Apr  7 00:53]
```

```
User's tokens for afs@bme.hu [Expires Apr  7 00:47]
```

Megvalósítás

- A kliens oldali programok a szokásos módon, rendszerhívással kezelik az állományokat.
- A távoli fájlok megnyitásakor Venus processzhez jut a kérés, amit az lebont az útnév alapján.
- Az alacsonyszintű I/O kezelését a befogadó operációs rendszer végzi. A gyorsítótár a lokális gép diszkjén jön létre.

Rendszerhívás szint



AFS parancsok

Az AFS parancsok 3 csoportba oszthatók:

- Fájlszerver parancsok (fs)
 - AFS szerver információk listázása
- Védelmi parancsok(pts)
 - ACL listák létrehozása
- Authentikációs parancsok
 - klog, unlog, kpasswd, tokens

AFS előnyei

- Gyorsítótárazásból fakadó előnyök:
 - Lényegesen csökkenti a hálózati forgalmat.
 - Alacsonyabb sávszélességnél is jól használható.
- Helyfüggetlenség:
 - Az AFS a földrajzi helyet a szerver oldalon rendeli fájlnevhez. Így a névtér helyfüggetlen.
- Skálázhatóság:
 - A rendszer tervezési fázisában igen nagyra (~10000 kliens) tervezték. A kliens/szerver arányt pedig 200:1-re. Mindkét értéket túlteljesíti.

AFS előnyei /2

- Single systems image (SSI):
 - Egy fájlserver kialakítása lényegesen egyszerűbb, mint NFS-sel.
- Fokozott biztonság:
 - Kerberos használata
 - ACL használata
- Fájlok egyszerű megosztása
- Egyszerű rendszer menedzsment
- Robosztus
- Replika lehetőség.

AFS hátrányai



- Minden munkaállomásra installálni kell.
- Háttérszerver komplexitása.
- Tokenek érvényességének lejártából fakadó gondok.


Lustre

- Objektum-orientált elosztott fájlrendszer.
- Jól skálázható.
- Nagyméretű klaszterekhez, és nagy fájlokhoz tervezték.
- Lustre 2007-től GPL.
- SUN ZFs
- top 30 szupergépből 15 Lustre fájlrendszert használ.

Lustre történelem

- 1999 by Carnegie Mellon University
- Lustre 1.0 2003-ban (Cluster File Systems)
- 2007-ben SUN felvásárolta a CFS-t.
 - Open source software (RedHat, SUSE, ...)
- 2010-ben Oracle felvásárolta az SUN-t
 - 2011-ben 1.8 supportot megszüntette (számos szervezet folytatta)
 - Whamcloud, **OpenSFS**, EOFS,
- 2012-ben Whamcloud-ot megvette az INTEL
- 2019- OpenSFS és EOFS visszaszerzi a nevet
- 2022: Lustre 2.15
- 2024: Lustre 2.16

Lustre Community Roadmap



* Estimates are not commitments and are provided for informational purposes only


* Fuller details of features in development are available at <http://wiki.lustre.org/Projects>



Lustre architektúra

- Három fő funkcionális egysége van:
- Metadata szerver (MDS), ami a fájl neveket, katalógusokat, védelmi kódokat és egyéb metaadatot tárol.
- Object storage szerverek (OSS), melyek az adatokat tárolják.
- Kliens ami az adatokat felhasználja, létrehozza.

Lustre architektúra




Lustre architektúra /2

- Az adatok logikai kötetmenedzsmenttel ellátott RAID tárolókban tárolódnak, amit az OSS és az MDS dedikált módon használ.
- Jelenleg egy módosított ext4 fájlrendszer a logikai tároló. ZFS support
- Amikor egy kliens fájlt akar elérni, először az MDS-ben meg kell keresnie.

Lustre architektúra /2

- A fájl egyes darabjai több OSS-en tárolódhatnak, ami a kliens és az OSS között szűk keresztmetszet kialakulását gátolja.
- A kliensek nem módosítják közvetlenül az OSS-ben tárolt adatokat, hanem ezt a OSS-re bízzák, szemben a GFS megoldásával.
- Ez a módszer növeli a megbízhatóságot és a hibatűrést.

Ceph



Ötlet azonos: Metadata és az adatok szétválasztása.

2007: doktori disszertáció, 2010 Linux, 2012: Inktank

2014: RedHat, 2015: Ceph CE

2023: Ceph Reef

2024: Squid


Ceph jellemzői

1. Adat és metaadat teljes szeparációja
 - Objektum alapú tároló
 - Független metaadat tárolás
 - CRUSH – adatelosztási funkció
2. Intelligens diszkek (RADOS)
 - Megbízható autonóm elosztott objektum tároló
3. Dinamikus metaadat menedzsment
 - Adaptív és skálázható

CRUSH

Inode helyett CRUSH


- Teljesen leírja az adatok elhelyezkedését
- Kiszámítható az objektumok elhelyezkedése
- Elosztott, hierarchikus
- Nincs allokációs lista
- Kis helyen tárolható



RADOS

RADOS: Reliable Autonomic Distributed Object Store


- Intelligens OSD
 - OSD-k páronként kommunikálnak
- OSD-k egy logikai tárolót alkotnak
 - megbízhatóak
 - önmenedzselők
 - elosztottak
- EBOFS a lokális tárolásért felel



Alacsony-szintű tárolás

EBOFS: Extent and B-tree-based Object File System

- copy-on-write technika alkalmazása
 - Egyszerű visszalépni egy előző konzisztens állapotba
- User-space implementáció
 - Nem használ VFS-t



ZFS

- Sun: 2001-2004, 2005-től Solaris része
- 2010-ben Oracle felvásárolja a Sun-t
- Zettabyte File System
- 128 Bit - extra nagy kapacitás
- Pool elvű tárolók – elosztott sávszélesség és kapacitás
- Tranzakció kezelés – Copy on Write
- Snapshots (ro) és klónozás
- Adat integritás – ellenőrző összeg (külön)

ZFS kapacitások

- $1 \text{ ZB} = 10^{21}$ $1 \text{ ZiB (zebi B)} = 2^{70}$
- 2^{64} snapshot
- 2^{48} fájl / dir
- 2^{64} byte / fájl
- 2^{78} byte / pool
- 2^{64} device / pool
- 2^{64} pool / system

Hogyan kapunk diszk címet

Hagyományos FS esetén:

- FS(1): filename $\rightarrow$ object (inode)
- FS(2): object $\rightarrow$ volume LBA
- VM: volume LBA $\rightarrow$ array LBA
- RAID: array LBA $\rightarrow$ disk LBA

Sok réteg, szigorú szeparáció, eltérő gyártók

Hogyan kapunk diszk címet (2)

ZFS esetén:

- ZPL: filename $\rightarrow$ object
- DMU: object $\rightarrow$ DVA
- SPA: DVA $\rightarrow$ LBA


ZPL: ZFS POSIX layer (standard syscall)

DMU: Data Management Unit (transactional object store)


DVA: Data Virtual Address (vdev + offset)

SPA: Storage Pool Allocator (block alloc, data transform)

ZFS Architektúra




ZFS – VM hasonlóság




Kötet és Pool





- Hagyományos kötet kezelés




- Pool:
 - Automatikus méretezés
 - osztott sávszélesség



ZFS - Copy on Write (COW)



ZFS – ellenőrző összeg



ZFS elérhetősége


- OpenSolaris, OpenIndiana
- BSD, OSX
- Linux: CCDL és a GPL üti egymást
- OpenZFS – 2013-tól (Linux 6.x)
- Linux FUSE
- Native ZFS (Gentoo, Ubuntu, LLNL)

<http://en.wikipedia.org/wiki/ZFS>


GlusterFS

- Célkitűzés FUSE alapokon megvalósítani elosztott fájlrendszert.
- A céget 2011-ben megvette a RedHat, minek hatására a közösség láthatóan hanyatlásnak indult.
- 2013-ban újra megindult a fejlesztés
- 2015-től RH nagyon tolja
- 2019-ben IBM felvásárolja a RH-t
- Legutolsó verzió: 11.x (2024)


GlusterFS – Distributed Vol.




GlusterFS – Replicated Vol.




Distributed Replicated Vol.



FUSE



Működés



CernVM-FS

- Cél: Programok és kísérleti adatok (LHC) elérésének biztosítása a kutatók számára.
- Tartalom alapú tároló
- HTTP → tűzfalak átengedik
- Adatok integritásának ellenőzése hash-ekkel.


CernVM-FS /2

- POSIX read-only fájlrendszerként van megvalósítva (FUSE)
- HTTP cache
- Adatok és metaadatok átvitele on demand módon.
- Főleg SL (Scientific-Linux) disztribúciókhoz

EOS – CERN fájlrendszere

- Nagy teljesítményű, skálázható elosztott fájlrendszer.
- Nagy I/O teljesítmény petabájtos és exabájtos adatmennyiségekhez.
- Rugalmas, többprotokollos hozzáférés (POSIX, HTTP, WebDAV, XRootD)
- Magas rendelkezésre állás és hibatűrés.
- Skálázhatóság több adatközpont között.
- CERN SSO, X.509, Kerberos, LDAP
- OpenSource

Cern-EOS Architektúra



AFS → EOS

Fő örökségek az AFS-ből az EOS-ban:

- Globális namespace – /afs/... → /eos/... Logika
- ACL alapú jogosultságkezelés → ACL + AuthZ plugin rendszer
- Replikációs elv – volume replication → namespace-level replica sets
- Szervezeti modell – cellák → EOS 'space' és 'instance' fogalmak

Különbségek:

- Teljesen új technológiai alap: Redis / QuarkDB metaadat, XRootD / HTTP hozzáférés
- Nincs AFS-kliens cache, hanem szerveroldali caching és multi-protocol access
- Modern REST és POSIX interfészek, multi-site architektúra

Quobyte

The logo consists of a horizontal bar with a color gradient from dark blue on the left to bright yellow on the right.

- Diszk-bázisú objektum orientált tároló
- Skálázható
- Redundáns (0. v. 3 replika)
- HPC környezet
- HA és FT
- Multi-tenant

Melyiket hol használják?

- Szuperszámítógépek, nagy felhők
 - Lustre, Sepectrum Scale, BeeGFS, WekaFS, DAOS
- Department/divízió
 - NFS, SMB/CIFS, AFS (legacy), GlusterFS, CephFS
- Wokrgroup
 - SMB, NFS, Lokális NAS
- Teljesítmények összehasonlítása
 - IO-500 lista + közösség

Top HPC fájlrendszerek

1. Frontier (OLCF, USA) – Lustre – Exascale rendszer, Cray Slingshot interconnect
2. Alps (CSCS, Svájc) – BeeGFS – GPU-optimalizált, DGX SuperPOD architektúra
3. Fugaku (RIKEN, Japán) – Fujitsu FEFS – NVMe-alapú, sűrű IO optimalizálás
4. LUMI (CSC, Finnország) – Lustre – EuroHPC infrastruktúra, ZFS backend
5. JUPITER Booster (FZJ, Németország) – IBM Spectrum Scale – Multi-tier caching, magas sávszélesség
6. Perlmutter (NERSC, USA) – Lustre + all-flash tier – GPU-rétegzett HPC architektúra

Top HPC fájlrendszerek

7. ThetaGPU (ALCF, USA) – Ceph + Lustre hybrid – Ceph alapú objektumtároló integráció
8. Marconi100 (CINECA, Olaszország) – Spectrum Scale – IBM Power9 környezetre hangolt
9. Selene (NVIDIA, USA) – WekaFS – AI/HPC hibrid rendszer, extrém alacsony latency
10. CERN-EOS (CERN, Svájc) – EOS – Kutatási adatok POSIX + HTTP hozzáféréssel

Forrás: io500.org/list (2025. június)

IO-500.org alapján

Fájlrendszer	Top 15-ben	Top 500-ban	Megjegyzés
DDN EXAScaler / Lustre	7	200	Exascale HPC-rendszerek fő fájlrendszere
DAOS (Intel)	4	20	Új generációs, objektumalapú, NVM-optimalizált FS
WekaIO / WekaFS	2	10	AI-orientált, NVMe-alapú FS
Nyílt Lustre (community)	2	200	Klasszikus open-source Lustre
IBM Spectrum Scale / Storage Scale	0	60	Széles körben használt,
BeeGFS	0	40	Közepes méretű GPU-klaszterekben
Ceph	0	8	Kiegészítő objektumtárolóként
EOS (CERN)	0	5	Tudományos adatarchívumokban
Egyéb (pl. Panasas, xFusion)	0	10	Kis mintában, speciális OEM-megoldások

Trendek

- Lustre továbbra is domináns a HPC klaszterekben.
- BeeGFS gyorsan terjed GPU-orientált rendszereknél.
- Spectrum Scale (GPFS) erős vállalati környezetekben.
- Ceph megjelent mint hibrid objektumtároló (ThetaGPU).
- CERN-EOS továbbra is meghatározó az európai tudományos adatinfrastruktúrában.